3️⃣

[3주차] 4장 엘라스틱서치:검색

4.1 쿼리 컨텍스트와 필터 컨텍스트

- 쿼리 컨텍스트

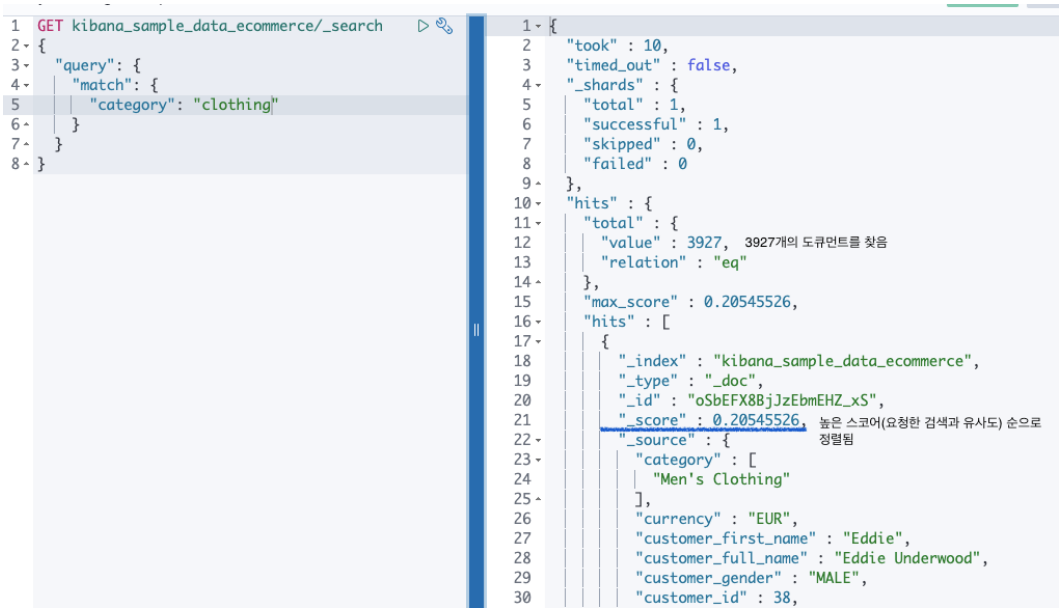

  - 질의에 대한 유사도 계산 기준으로 정확한 결과 반환
  - 결과값: 연관성에 따른 스코어
- 필터 컨텍스트

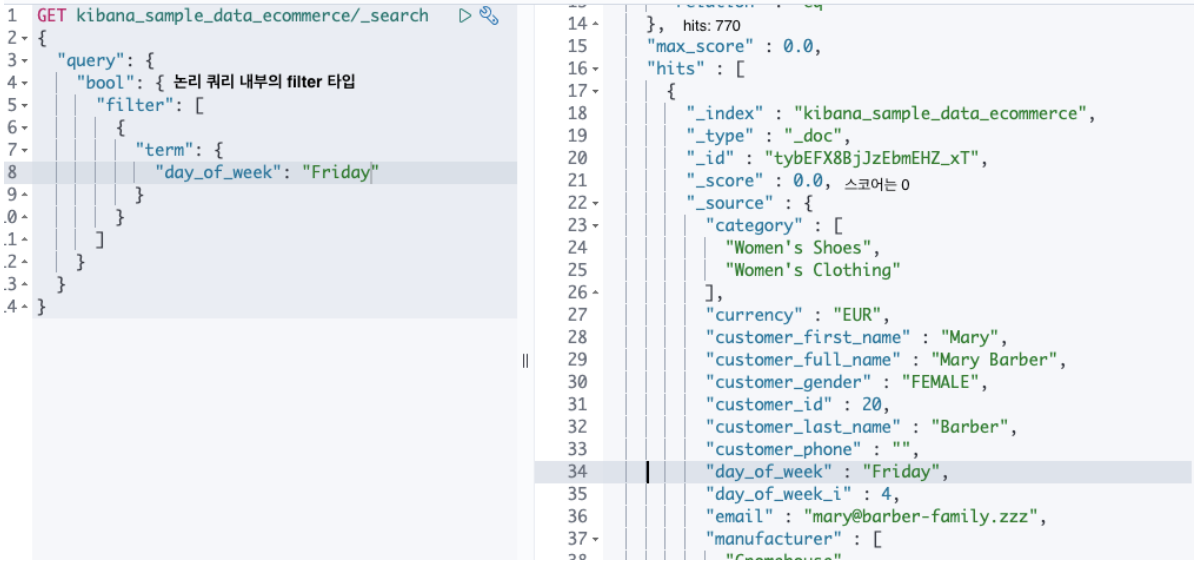

    - 유사도 계산 X (스코어 계산 X)
        - 속도 향상
        - 캐시
    - 일치 여부에 따른 결과만 반환
    - 결과값: 예/아니요
- 쿼리/필터 조합으로 사용하는 추세임

4.2 쿼리 스트링과 쿼리 DSL

- 쿼리 스트링:
    - 한 줄의 간단한 쿼리
    - 복잡해지면 가독성이 떨어질 수 있음

```
GET kibana_sample_data_ecommerce/_search?q
  =customer_full_name:Mary
```

쿼리스트링


```
{
  "took" : 7,
  "timed_out" : false,
  "_shards" : {
    "total" : 1,
    "successful" : 1,
    "skipped" : 0,
    "failed" : 0
  },
  "hits" : {
    "total" : {
      "value" : 154,
      "relation" : "eq"
    },
    "max_score" : 3.4912553,
    "hits" : [
      {
        "_index" : "kibana_sample_data_ecommerce",
        "_type" : "_doc",
        "_id" : "oibEFX8BjJzEbmEHZ_xT",
        "_score" : 3.4912553,
        "_source" : {
          "category" : [
            "Women's Clothing"
          ],
          "currency" : "EUR",
          "customer_first_name" : "Mary",
```


- 쿼리 DSL:

```
GET kibana_sample_data_ecommerce/_search
{
  "query": {
    "match": {
      "customer_full_name": "Mary"
    }
  }
}
```

쿼리DSL


```
{
  "took" : 3,
  "timed_out" : false,
  "_shards" : {
    "total" : 1,
    "successful" : 1,
    "skipped" : 0,
    "failed" : 0
  },
  "hits" : {
    "total" : {
      "value" : 154,
      "relation" : "eq"
    },
    "max_score" : 3.4912553,
    "hits" : [
      {
        "_index" : "kibana_sample_data_ecommerce",
        "_type" : "_doc",
        "_id" : "oibEFX8BjJzEbmEHZ_xT",
        "_score" : 3.4912553,
        "_source" : {
          "category" : [
            "Women's Clothing"
          ],
          "currency" : "EUR",
          "customer_first_name" : "Mary",
```


  - 복잡한 쿼리
  - 엘라스틱서치에서 제공하는 쿼리 전용 언어
  - JSON 기반의 직관적인 언어

4.3 유사도 스코어

- 질의문과 도큐먼트의 유사도 표현값

- 높은 스코어 → 높은 연관
- 쿼리에 `explain 옵션`을 사용해 유사도 스코어 알고리즘을 알 수 있다.
- 기본적으로 BM25 알고리즘 사용

BM25 알고리즘

- 검색, 추천에 많이 사용
- TF + IDF + 문서 길이 를 고려한 알고리즘
- IDF 계산
  - 문서 빈도 : 특정 용어가 얼마나 자주 등장했는지 의미
  - 문서 빈도가 높다 → 중요한 용어가 아님 (ex. 관사, 부사)
  - 문서 빈도의 역수(IDF): 도큐먼트 내에 발생 빈도가 적을수록 가중치를 높여주는 것

```
{
  "value" : 7.1974354,
  "description" : "idf, computed as log(1 + (N - n + 0.5) / (n + 0.5)) from:",
  "details" : [
    {
      "value" : 3,
      "description" : "n, number of documents containing term",
      "details" : [ ]
    },
    {
      "value" : 4675,
      "description" : "N, total number of documents with field",
      "details" : [ ]
    }
```

n: 3, N: 4675

    - n: 검색했던 용어가 몇 개의 도큐먼트에 있는지
    - N: 인덱스의 전체 도큐먼트 수
- TF 계산
  - 용어 빈도 : 특정 용어가 하나의 도큐먼트에 얼마나 많이 등장했는지 의미
  - 용어 빈도가 높다 → 주제 용어

```
{
  "value" : 0.52217203,
  "description" : "tf, computed as freq / (freq + k1 * (1 - b + b * dl / avgdl)) from:",
  "details" : [
    {
      "value" : 1.0,
      "description" : "freq, occurrences of term within document",
      "details" : [ ]
    },
    {
      "value" : 1.2,
      "description" : "k1, term saturation parameter",
      "details" : [ ]
    },
    {
      "value" : 0.75,
      "description" : "b, length normalization parameter",
      "details" : [ ]
    },
    {
      "value" : 5.0,
      "description" : "dl, length of field",
      "details" : [ ]
    },
    {
      "value" : 7.3161497,
      "description" : "avgdl, average length of field",
      "details" : [ ]
    }
  ]
}
```


- feq : 도큐먼트 내에서 용어가 나온 횟수
- k1, d : 알고리즘을 정규화하기 위한 가중치
- dl : 필드 길이
- avgdl : 전체 도큐먼트에서 평균 필드 길이

- BM25알고리즘 최종 값 = IDF * TF * boost(2.2)


```
      "description" : "score(freq=1.0), computed as boost * idf * tf from:",
      "details" : [
        {
          "value" : 2.2,
          "description" : "boost",
          "details" : [ ]
        },
        {
```


  - boost: 고정값 = 2.2

4.4 검색 쿼리 search query

- 종류
  - 리프 쿼리 leaf query
    - 특정 필드에서 용어 찾는 용도
    - 매치, 용어, 범위 쿼리
  - 복합 쿼리 compound query
    - 쿼리 조합
    - 논리 쿼리
- 전문 쿼리
  - 전문 검색용
  - 텍스트 타입 매핑
  - 전문 쿼리 과정

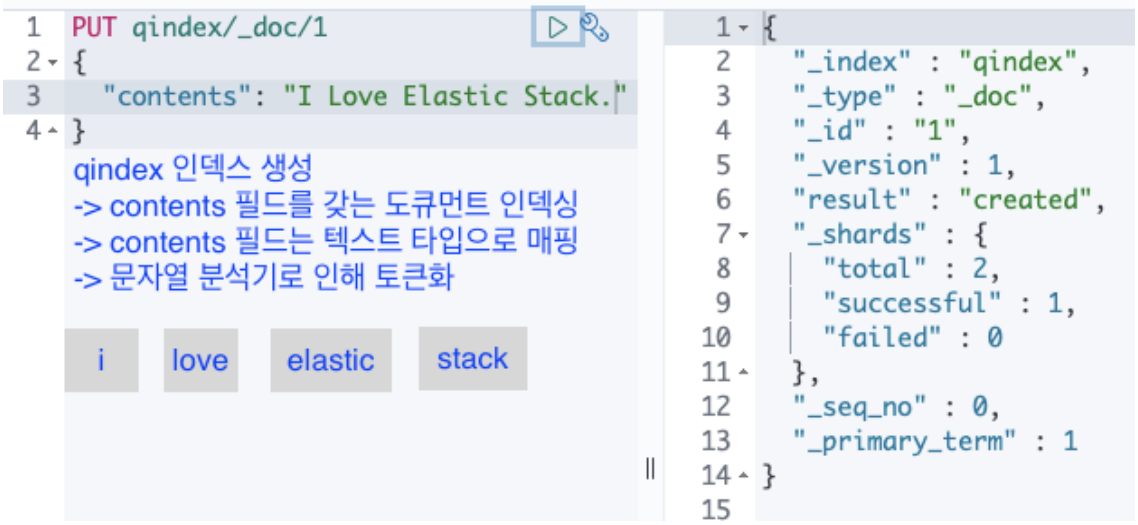

일반적인 분석기는 대문자를 소문자로 변경한다.

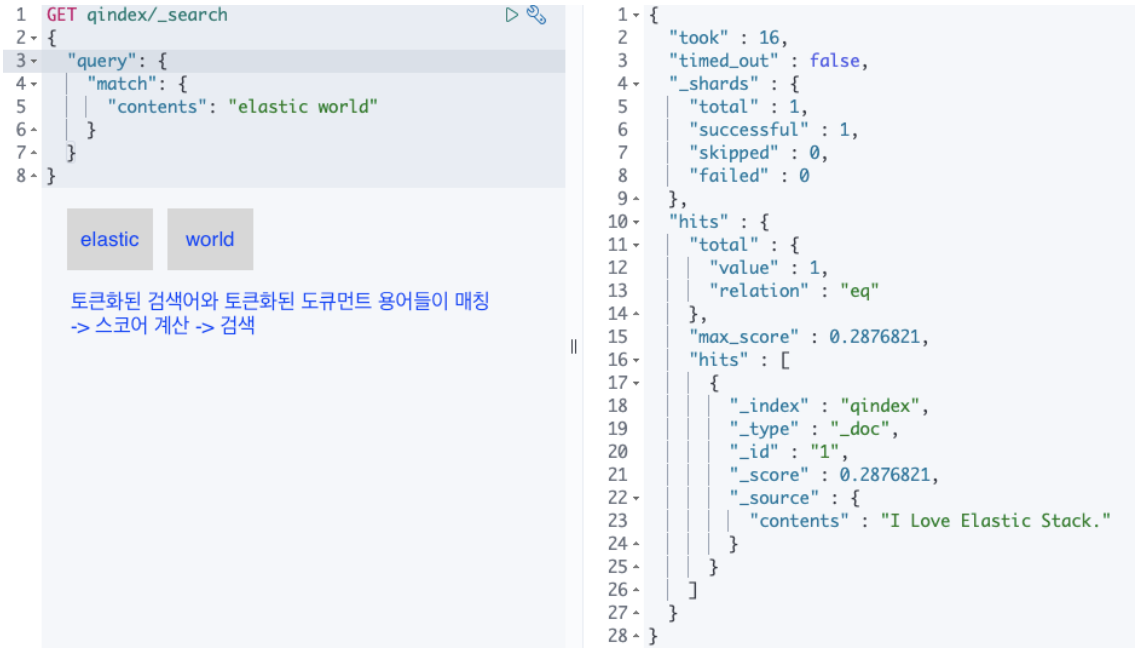

- 구글, 네이버 검색 방식
- 종류: 매치 쿼리(match), 매치 프레이즈 쿼리(match phrase), 멀티 매치 쿼리(multi-match), 쿼리 스트링 쿼리(query string)
- 매치 쿼리

operator 파라미터를 and 로 변경하면 검색어를 모두 포함한 검색을 한다

  - 전문 쿼리의 가장 기본

        - 특정 용어나 용어들 검색용
    - 매치 프레이즈 쿼리
        - 2개 이상의 단어가 연결되어 만들어진 단어를 검색 (순서도 맞아야함)
        - 검색시 많은 리소스를 요구하기 때문에 자주 사용하는 것은 좋지 않다.
    - 멀티 매치 쿼리
        - 어떤 필드가 저장되었는지 모를 때 사용
        - 전문 검색 쿼리
        - 1개 이상의 필드에 쿼리 요청 가능
            - 개별 스코어를 구한 후 가장 큰 값이 대표 스코어값이 된다.
            - 검색하려는 필드가 많을 때 *(와일드카드)를 사용해서 유사한 복수 필드를 선택할 수 있다.

        - 필드에 가중치 두기 = 부스팅 기법
            - 중요한 필드에 가중치를 둘 수 있다.

```
GET kibana_sample_data_ecommerce/_search
{

  "query": {
    "multi_match": {
      "query": "mary",
      "fields": [
        "customer_full_name^2",
        "customer_first_name",
        "customer_last_name"
      ]
    }
  }
}
```

    - 필드이름^n ⇒ 필드의 스코어 값을 n 배 해준다.

- 용어 쿼리
    - 정확히 일치하는 용어 검색용
    - 키워드 타입 매핑
    - 용어 쿼리 과정

```
PUT qindex/_doc/1
{
  "category": "Tech"
}
```

qindex 인덱스 생성
-> category 필드를 갖는 도큐먼트 인덱싱
-> category는 키워드타입으로 매핑
-> 분석기X

```
{
  "_index" : "qindex",
  "_type" : "_doc",
  "_id" : "1",
  "_version" : 1,
  "result" : "created",
  "_shards" : {
    "total" : 2,
    "successful" : 1,
    "failed" : 0
  },
  "_seq_no" : 0,
  "_primary_term" : 1
}
```

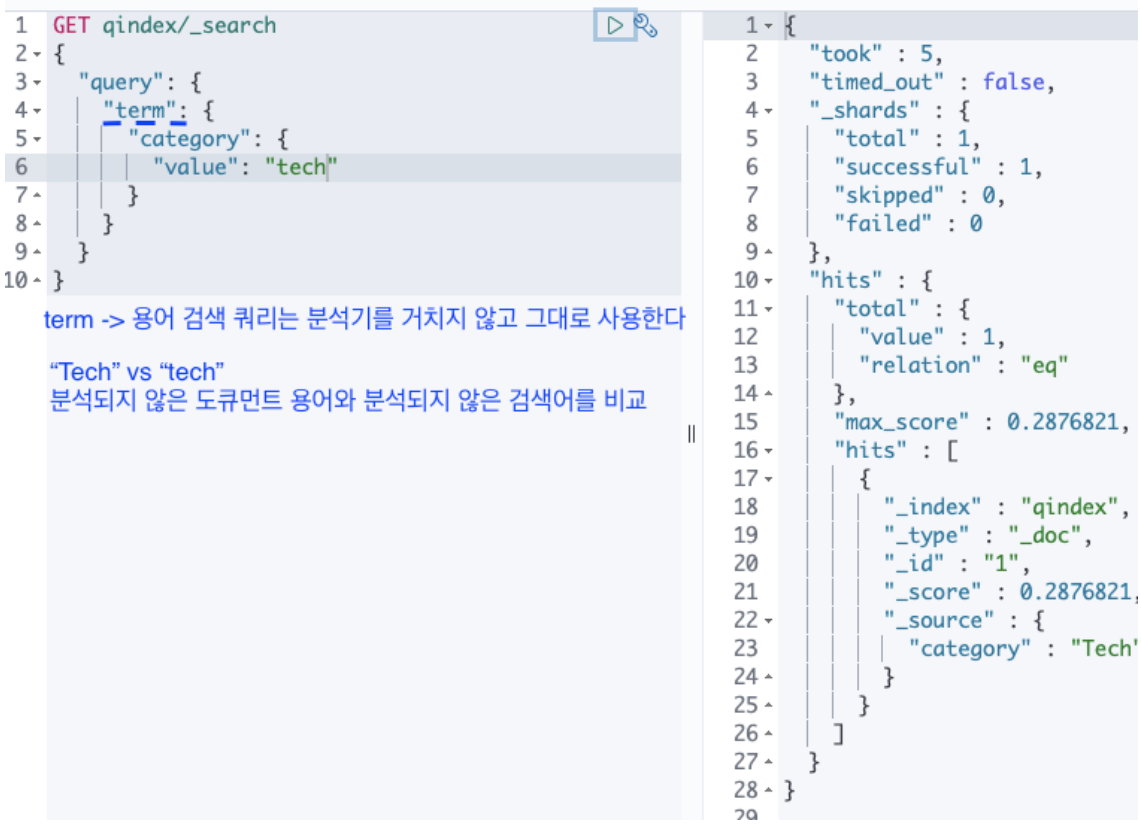

- 키워드, 숫자형, 날자, 범위형 타입의 필드에서 검색할 때 사용
- 종류: 용어 쿼리(term), 용어들 쿼리(terms), 퍼지 쿼리(fuzzy)
- 용어 쿼리
  - 텍스트 타입 필드에 용어 쿼리사용은 올바르지 않다

```
GET kibana_sample_data_ecommerce/_search
{
  "_source": ["customer_full_name"],
  "query": {
    "term": {
      "customer_full_name": "Mary Bailey"
    }
  }
}
```

"Mary Baily" vs ["mary", "bailey"]

```
{
  "took" : 0,
  "timed_out" : false,
  "_shards" : {
    "total" : 1,
    "successful" : 1,
    "skipped" : 0,
    "failed" : 0
  },
  "hits" : {
    "total" : {
      "value" : 0,
      "relation" : "eq"
    },
    "max_score" : null,
    "hits" : [ ]
  }
}
```

cutomer_full_name은 텍스트 타입이다.

- 키워드 타입 필드에 대한 용어 쿼리는 .keyword로 변경하면 된다.

```
GET kibana_sample_data_ecommerce/_search
{
  "_source": ["customer_full_name"],
  "query": {
    "term": {
      "customer_full_name.keyword": "Mary Bailey"
    }
  }
}
```

```
      "_index" : "kibana_sample_data_ecommerce",
      "_type" : "_doc",
      "_id" : "oibEFX8BjJzEbmEHZ_xT",
      "_score" : 7.1974354,
      "_source" : {
        "customer_full_name" : "Mary Bailey"
      }
    },
    {
      "_index" : "kibana_sample_data_ecommerce",
      "_type" : "_doc",
      "_id" : "PSbEFX8BjJzEbmEHZ_1V",
      "_score" : 7.1974354,
      "_source" : {
        "customer_full_name" : "Mary Bailey"
      }
    },
    {
      "_index" : "kibana_sample_data_ecommerce",
      "_type" : "_doc",
      "_id" : "_CfEFX8BjJzEbmEHdgvA",
      "_score" : 7.1974354,
      "_source" : {
        "customer_full_name" : "Mary Bailey"
      }
    }
```

  - 용어들 쿼리

- 범위 쿼리
  - 특정 날짜, 숫자 범위 검색용
  - 문자형, 키워드 타입의 데이터에서 사용불가
  - 범위 지정 파라미터
    - gte
    - gt
    - lte
    - lt
  - 날짜/시간 데이터 타입 표현식
    - now : 현재시각
    - now+1d: 현재시각 + 1일
    - now+1h+30m+10s: 현재시각 + 1시, 30분, 10초
    - 2021-01-21||+1M : 2021-01-21 +1달
  - 날짜/시간 단위 표기법
    - y (연), d(일), s(초), M(월), H/h(시), w(주), m(분)
  - 범위 데이터 타입 (date_range)

        - 날짜/ 시간타입(date)과 다르다.
        - `relation` 파라미터로 시작, 끝 범위를 지정한다.
    - relation에 들어갈 수 있는 값들
        - intersects(default): 쿼리 범위 값이 도큐먼트 범위 데이터를 일부라도 포함하기만 하면 된다.
        - contains: 도큐먼트의 범위 데이터가 쿼리 범위 값을 모두 포함해야 한다.
        - within: 도큐먼트의 범위 데이터가 쿼리 범위 값 내에 전부 속해야 한다.
- 논리 쿼리
    - 복합 쿼리
    - 논리 쿼리 타입
        - must:

          쿼리를 실행하여 참인 도큐먼트를 찾는다.

          복수 쿼리를 실행하려면 AND 연산을 한다.
        - must_not:

          쿼리를 실행하여 거짓인 도큐먼트를 찾는다.

          다른 타입과 같이 사용할 경우 도큐먼트에서 제외 한다.
        - should:

          단독으로 사용 시 쿼리를 실행하여 참인 도큐먼트를 찾는다

          복수의 쿼리를 실행하면 OR 연산을 한다

          다른 타입과 같이 사용할 경우 스코어에만 활용한다.
        - filter:

          쿼리를 실행하여 예/아니오 형식의 필터 컨텍스트를 수행한다.
    - 패턴 검색
        - 용어 수준 쿼리
        1. 와일드카드 쿼리

- 검색어 앞에 *(모든 문자 매칭) 또는 ?(한문자 매칭)을 쓰면 속도가 매우 느려진다.

2. 정규식 쿼리
    - +,?,* 같은 기호는 맨 앞에 올 수 없다.
    - () 기호는 문자를 그룹핑해 반복되는 문자를 매칭한다
    - []기호는 문자를 클래스화해 특정 범위의 문자들을 매칭한다.